IA PARA DEVS – FASE 2 – TECH CHALLENGE

Otimização de Modelos de Diagnóstico

Carmen Lívia de Siqueira Lopes
Matrícula: RM375965

Novembro de 2026

1 Escopo

Foi feita a implementação de busca genética de hiper parâmetros para Regressão Logística e Árvore de Decisão, com seleção por validação cruzada e avaliação final em conjunto de teste reservado. Uma API local que encaminha resultados informados a um endpoint de LLM compatível com Chat Completions e apresenta uma explicação em português.

O algoritmo genético foi executado em seis buscas. Os candidatos escolhidos tiveram menor Recall maligno no teste que os modelos de referência. A integração com a LLM e seu protocolo de avaliação estão implementados, mas não houve chamadas reais nem revisão de respostas; portanto, a qualidade textual ainda não foi medida.

2 Algoritmo genético (GA)

Implementação

Cada indivíduo representa uma configuração de hiper parâmetros. O GA cria uma população, avalia os indivíduos em cinco folds estratificados apenas nos dados de treino e evolui as configurações por seleção, cruzamento, mutação e elitismo. O fitness é o Recall médio da classe maligna; F1 e precision são critérios de desempate. A seleção do candidato ocorre sem acesso ao teste.

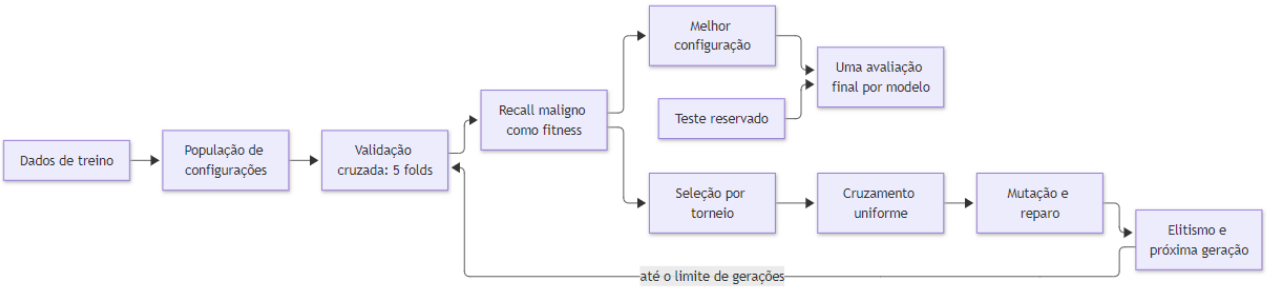


Figura 1 Fluxo da busca genética e avaliação final

O algoritmo inicializa somente configurações válidas, repara combinações incompatíveis após operadores genéticos e armazena avaliações repetidas em cache. Falhas de treinamento e avisos de não convergência não recebem fitness válido; os erros ficam registrados.

Modelo	Hiper parâmetros pesquisados
Regressão Logística	`C` entre 1e-4 e 1e4, `solver` (`lbfgs`, `liblinear`, `saga`) e `penalty` (`l1`, `l2`), respeitando as combinações válidas
Árvore de Decisão	`max_depth` entre 1 e 20 ou `None`, `min_samples_split` entre 2 e 30, `min_samples_leaf` entre 1 e 15 e `criterion` (`gini`, `entropy`, `log_loss`)

Na regressão, a padronização está dentro do pipeline e é ajustada novamente em cada fold, evitando que a validação participe do pré-processamento. A árvore usa os dados sem padronização.

Execuções e seleção

Foram realizadas três configurações de GA para cada modelo no estudo de 25/10/2026:

Busca	População	Gerações	Seed	Cruzam.	Mutação	Elitismo	Torneio
01	12	8	42	0,80	0,20	1	3

Busca	População	Gerações	Seed	Cruzam.	Mutação	Elitismo	Torneio
02	20	12	43	0,85	0,25	2	3
03	32	16	44	0,90	0,15	3	5

Em cada busca, a mutação reamostra cada gene com a probabilidade indicada. A configuração selecionada por modelo foi a de maior Recall médio em CV:

Modelo	Busca escolhida	Hiperparâmetros	Recall CV	F1 CV	Precision CV
Regressão Logística	03	`C=3507.06, solver=lbfgs, penalty=l2`	0,9647	0,9593	0,9552
Árvore de Decisão	02	`max_depth=20, min_samples_split=19, min_samples_leaf=14, criterion=log_loss`	0,9412	0,9305	0,9207

Nas buscas da Regressão Logística, foram registrados 3, 12 e 15 candidatos com falha nos experimentos 01, 02 e 03, respectivamente, principalmente por não convergência. Essas configurações não foram consideradas vencedoras.

Evolução do fitness

Os gráficos apresentam o melhor Recall em CV e a média da população por geração. Na regressão, o melhor Recall ficou em 0,9647 desde a população inicial; na árvore, passou de 0,9353 para 0,9412.

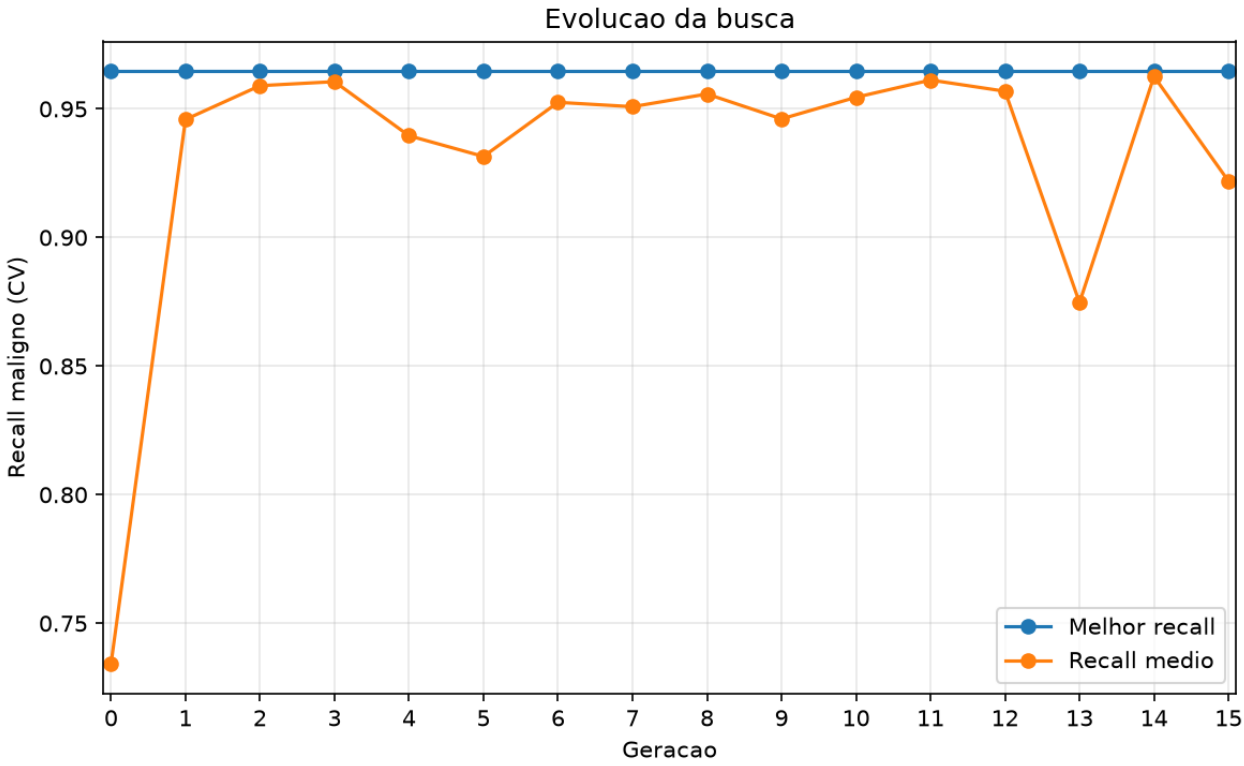


Figura 2 Evolução do Recall na busca escolhida da Regressão Logística

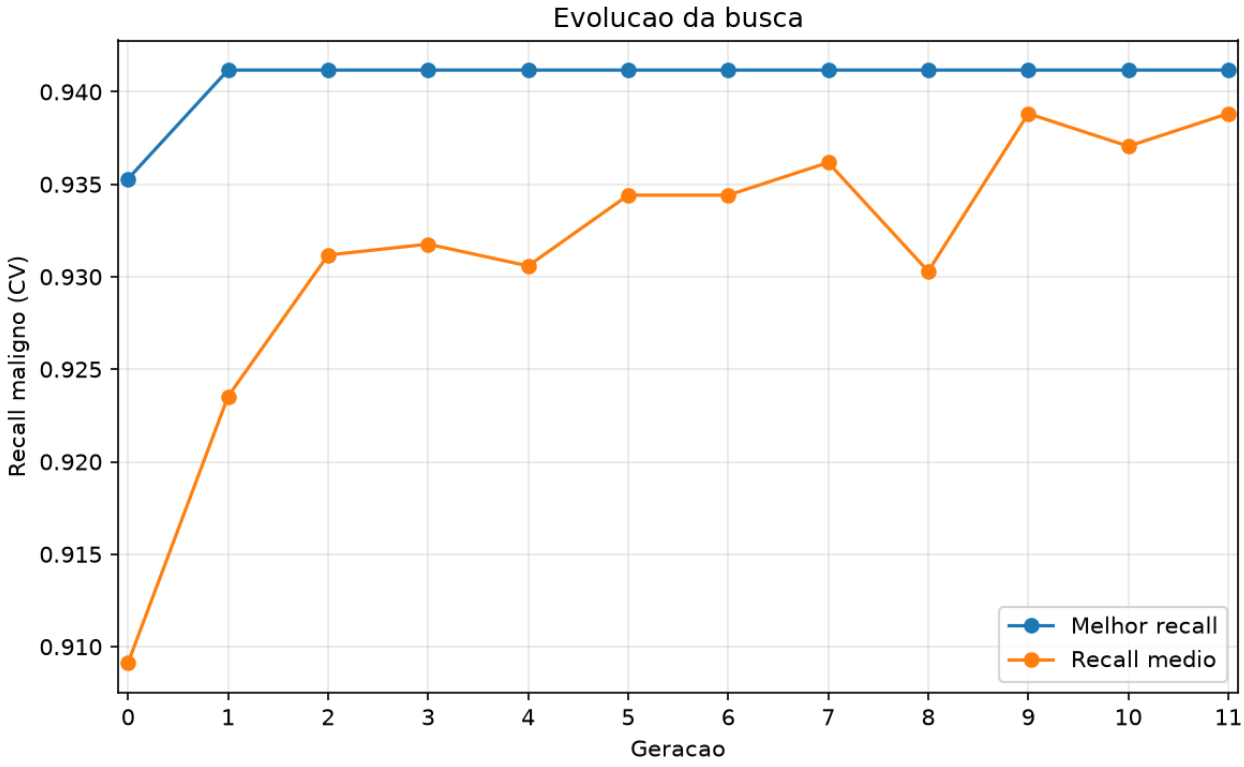


Figura 3 Evolução do Recall na busca escolhida da Árvore de Decisão

3 Comparativo de desempenho

Após selecionar as configurações em CV, cada modelo foi ajustado no treino completo e avaliado uma vez no teste reservado, com 114 exemplos. A classe positiva é maligna. `FN` indica malignos classificados como benignos.

Modelo	Versão	Accuracy	Precision maligna	Recall maligno	F1 maligno	FN
Regressão Logística	Original	0,9649	0,9750	0,9286	0,9512	3
Regressão Logística	Otimizada	0,9298	0,9250	0,8810	0,9024	5
Árvore de Decisão	Original	0,9386	0,9487	0,8810	0,9136	5
Árvore de Decisão	Otimizada	0,9386	1,0000	0,8333	0,9091	7

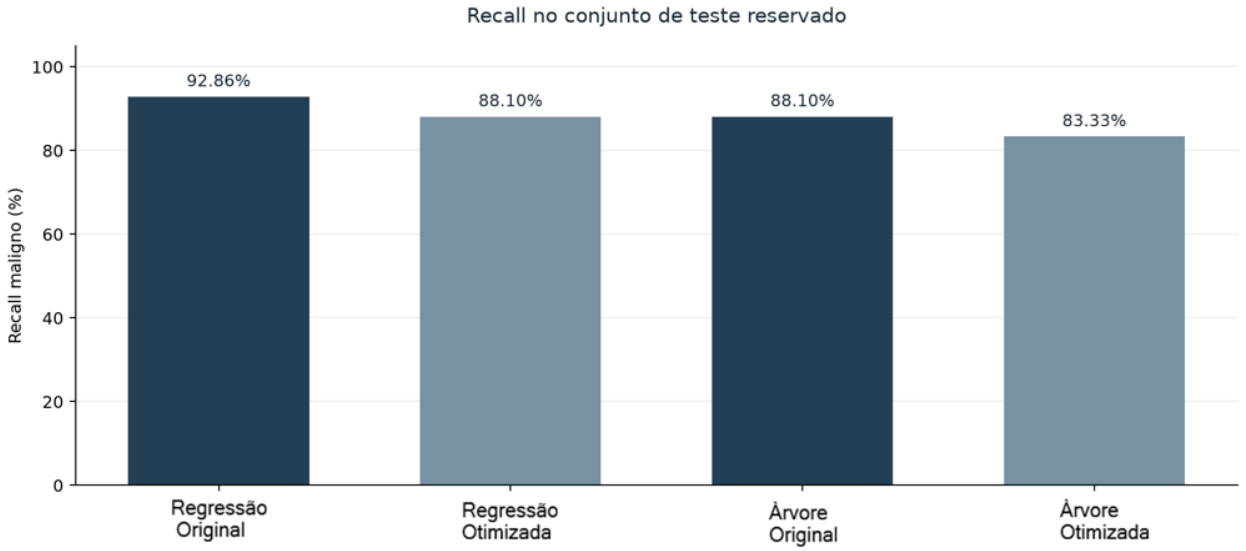


Figura 4 Comparação do Recall maligno no teste reservado

O Recall caiu 4,76 pontos percentuais nos dois modelos; em cada caso, houve dois falsos negativos a mais. A accuracy da árvore não mudou, mas a distribuição dos erros sim: os falsos positivos passaram de dois para zero, enquanto os falsos negativos subiram de cinco para sete. Assim, a otimização melhorou as métricas de CV dos candidatos escolhidos, mas não superou o baseline no objetivo principal do teste.

Essa comparação descreve um split específico, não comprova generalização. Há também diferença na configuração de treino: o pipeline otimizado da regressão usa `max_iter=2000`, enquanto a referência usa o padrão do estimador. Os resultados completos estão em final_comparison.md.

4 Integração com LLM e API

Fluxo implementado

A aplicação local usa `ThreadingHTTPServer`, sem framework web adicional. O formulário recebe a classe prevista, probabilidades e métricas já calculadas; o serviço **não executa predição** nem consulta o dataset. A função de interpretação valida os dados e envia uma chamada HTTPS ao endpoint configurado em `LLM_API_URL`. `LLM_API_KEY` e `LLM_MODEL` também são obtidos do ambiente.

O protocolo de avaliação prevê o endpoint da OpenAI com o modelo `gpt-4.1-mini`; essa configuração ainda não foi usada em uma coleta real.

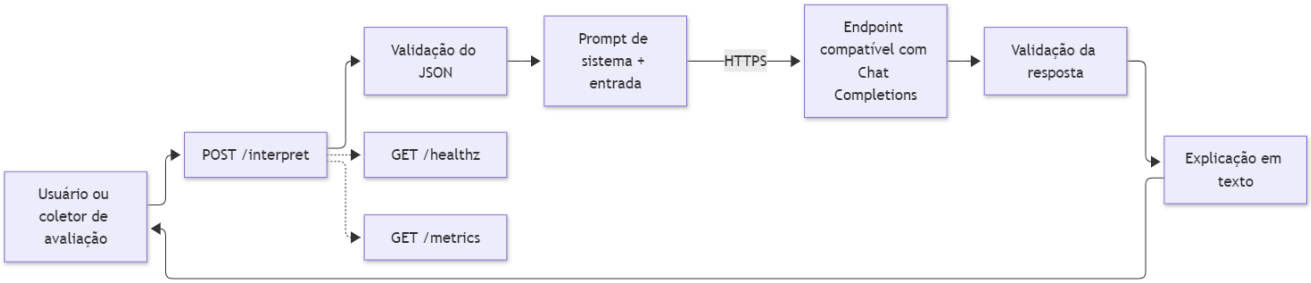


Figura 5 Fluxo da integração com a LLM

`POST /interpret` aceita somente `diagnosis`, `probabilities` e `metrics`. A classe deve ser `benigno` ou `maligno`; as duas probabilidades devem estar entre 0 e 1 e somar aproximadamente 1; `metrics` deve conter ao menos uma métrica válida (`accuracy`, `precision`, `recall` ou `f1`). Campos extras, valores não numéricos ou fora do intervalo são rejeitados. O corpo tem limite de 16.384 bytes.

A chave é enviada apenas no cabeçalho de autorização entre servidor e provedor. A API exige URL HTTPS, não registra corpos ou respostas nos logs rotineiros e exibe a resposta como texto. Erros de configuração, conexão, timeout ou resposta incompleta são informados como erro; não há interpretação fictícia de fallback. `/healthz` verifica apenas se o processo responde, não a disponibilidade do provedor. A especificação completa está em api.md.

Prompts utilizados

A mensagem de sistema orienta a LLM a explicar em português claro para profissionais de saúde e contém estas instruções:

```
Você explica resultados de modelos de classificação relacionados a câncer de mama em português claro para profissionais de saúde. Sua função é somente explicar os dados fornecidos, não diagnosticar uma pessoa nem orientar decisões de cuidado.

Regras obrigatórias:
- Trate a classificação e as probabilidades como saída de um modelo, não como diagnóstico clínico confirmado.
- Explique de forma concisa o que a classe e as métricas informadas permitem concluir; neste projeto, precision, recall e F1 referem-se à classe maligna, e accuracy é global. Não invente métricas, contexto, causas ou dados ausentes.
- Indique um ou dois pontos práticos para a equipe revisar sobre desempenho e validação do modelo, por exemplo o equilíbrio entre recall e precision. Não transforme esses pontos em recomendações para um paciente.
- Indique incerteza, limitações do modelo e que a interpretação deve ser considerada junto à avaliação profissional e ao contexto clínico.
- Não recomende tratamento, exames, procedimentos ou condutas para um paciente.
- Não revele nem infira dados pessoais. Se faltarem elementos, diga isso claramente.
- Organize a resposta nas seções "Resumo do resultado", "Leitura das métricas" e "Pontos de revisão do modelo" e "Limitações". Seja objetivo, cuidadoso e não use linguagem alarmista.
```

O prompt de usuário é um JSON com a classe, probabilidades e métricas validadas, por exemplo:

```
{
  "diagnosis": "maligno",
  "probabilities": {"benigno": 0.15, "maligno": 0.85},
  "metrics": {"accuracy": 0.8, "precision": 0.75, "recall": 0.75, "f1": 0.75}
}
```

Este é um caso sintético de desenvolvimento, não uma previsão de paciente. A chamada usa `temperature=0.2` e timeout de 30 segundos. A baixa temperatura busca reduzir variação, mas não garante correção. A rota e o coletor compartilham a validação de respostas vazias, interrompidas ou que contenham a chave configurada.

Avaliação da qualidade

O protocolo define dois casos de desenvolvimento e oito casos finais, com uma geração por caso. Quatro casos finais usam métricas dos modelos originais e otimizados; os outros quatro cobrem situações sintéticas, como Recall baixo, baixa precision, métricas parciais e valores extremos. **Todas as probabilidades individuais são sintéticas.**

5 Desafios e soluções

Desafio	Solução implementada	Resultado ou limite
Evitar que a busca use o teste para escolher parâmetros	Fitness recebe apenas treino; seleção por CV e teste reservado usado após a escolha	Mantém a separação da busca; o histórico dos notebooks anteriores é uma limitação
Gerar combinações válidas	Validação e reparo de genes depois de cruzamento e mutação; cache de avaliações repetidas	Combinações inválidas são rejeitadas ou reparadas; falhas de convergência ainda ocorrem na regressão
Traduzir resultados sem sugerir diagnóstico ou cuidado	Contrato restrito, prompt com limites explícitos e validação da resposta	Integração está implementada, mas ainda sem validação com respostas reais
Controlar chamadas e preservar evidências da avaliação	Coletor com teto compartilhado de dez tentativas, registro antes da chamada e congelamento do prompt na coleta final	Rastreabilidade implementada; coleta real e revisão humana pendentes
Interpretar o resultado negativo no teste	Relatar métricas e falsos negativos sem trocar o candidato após consultar o teste	O Recall caiu em ambos; a causa não foi isolada por este estudo